

# 人工智能第一次作业

## 拼音输入法实验报告

钟锦程 2026210748 电子工程系

2026 年秋

### 目录

|          |                           |          |
|----------|---------------------------|----------|
| <b>1</b> | <b>实验环境</b>               | <b>2</b> |
| <b>2</b> | <b>语料库与预处理</b>            | <b>2</b> |
| <b>3</b> | <b>基于字的二元模型</b>           | <b>2</b> |
| 3.1      | 概率模型 . . . . .            | 2        |
| 3.2      | Viterbi 解码 . . . . .      | 3        |
| <b>4</b> | <b>实验结果</b>               | <b>3</b> |
| 4.1      | 案例分析 . . . . .            | 3        |
| <b>5</b> | <b>改进方法：句首统计</b>          | <b>3</b> |
| <b>6</b> | <b>思考题</b>                | <b>4</b> |
| 6.1      | GBK、UTF-8 与其他编码 . . . . . | 4        |
| 6.2      | Viterbi 复杂度 . . . . .     | 4        |
| 6.3      | 两种输入输出代码 . . . . .        | 4        |
| <b>7</b> | <b>总结与感受</b>              | <b>5</b> |

## 1 实验环境

实验在 macOS 26.6.2 上完成, 处理器为 Apple M5 Pro, 内存为 24 GiB, Python 版本为 3.13.13。程序只使用 Python 标准库, 主要包括 json、collections、math、pickle 和 gzip。

新浪新闻语料和助教下发的两个汉字表使用 GBK 编码。程序使用兼容 GBK 的 GB18030 解码:

```
with path.open(encoding="gb18030") as source:
    ...
```

测试输入为 ASCII (也是 UTF-8 的子集), 标准答案和程序生成的 output.txt 使用 UTF-8。Python 在本实验终端中以 UTF-8 写标准输出, 评测脚本也显式以 UTF-8 写文件。

## 2 语料库与预处理

必做模型只使用助教提供的新浪新闻 2016 年 4 月至 11 月语料, 共 8 个 JSON Lines 文件。每行是一条新闻, 训练时读取其中的 title 和 html 字段。整个训练过程逐行进行, 内存中只保存计数, 不一次性加载约 831 MiB 的语料。

预处理步骤如下:

1. 读取“一二级汉字表”, 建立包含 6763 个合法汉字的集合;
2. 逐行解析新闻 JSON, 依次处理标题和正文;
3. 仅统计合法汉字的一元次数和相邻二元次数;
4. 遇到标点、数字、英文或字表外字符时断开上下文, 避免把标点两侧误算成相邻汉字;
5. 同时统计每个文本片段的首字, 供后续句首优化使用。

最终共处理 354,055,241 个合法汉字。没有使用 SMP2020 或外部语料, 以便保证实现和实验结论简单、可复现。

## 3 基于字的二元模型

### 3.1 概率模型

设汉字总数为  $N$ , 字库大小为  $V$ , 汉字  $c$  的出现次数为  $N(c)$ 。一元概率使用加一平滑:

$$P_1(c) = \frac{N(c) + 1}{N + V}. \quad (1)$$

对相邻汉字  $a, c$ , 二元条件概率与一元概率进行线性插值:

$$P(c | a) = \lambda \frac{N(a, c)}{N(a)} + (1 - \lambda) P_1(c), \quad (2)$$

其中  $\lambda = 0.99$ 。当二元组没有在训练语料中出现时，模型仍可回退到非零的一元概率。为避免很多小概率连乘产生浮点下溢，实际计算使用对数分数：

$$\text{score}(c_1 \dots c_n) = \log P_1(c_1) + \sum_{i=2}^n \log P(c_i | c_{i-1}). \quad (3)$$

### 3.2 Viterbi 解码

对输入的每个拼音，从拼音汉字表取得候选字集合。第  $i$  层的每个候选字尝试连接第  $i-1$  层所有候选字，只保留累计分数最高的路径和对应前驱。处理完最后一个拼音后，从最高分终点沿前驱指针反向恢复整句。

这种动态规划避免枚举全部候选句子，同时保留了二元模型下的全局最优路径。程序逐行读取标准输入并逐行输出，不在标准输出中打印训练日志或调试信息。

## 4 实验结果

测试集实际包含 501 句、5235 个汉字。表 1 给出同一次完整训练后的结果。

表 1: 本地测试结果

| 方法          | 字准确率   | 句准确率   | 501 句预测时间 | 模型大小     |
|-------------|--------|--------|-----------|----------|
| 普通二元模型      | 84.05% | 39.52% | 约 0.9 秒   | 8.86 MiB |
| 二元模型 + 句首统计 | 83.90% | 40.12% | 约 0.9 秒   | 8.86 MiB |

生成词频模型耗时 98.91 秒，压缩后的模型文件大小为 8.86 MiB。两种方法均超过作业要求的字准确率 80% 和句准确率 35%。

### 4.1 案例分析

普通新闻表达通常效果较好。例如输入 qing hua da xue 和 ren gong zhi neng 时，模型分别输出“清华大学”和“人工智能”。句首统计还纠正了若干首字错误：普通模型把 de guo zong li 输出为“的国总理”，加入句首统计后得到“德国总理”；dai kou zhao 也由“大口罩”变为“戴口罩”。原因是“德”“戴”作为片段首字比“的”“大”更合理。

较差结果主要来自训练领域和二元上下文的限制。例如 chuang qian ming yue guang 的答案是“床前明月光”，模型输出“创千名越广”；sheng hua huan cai 的答案是“生化环材”，模型输出“省华垠蔡”。古诗、缩略语和低频专名在新闻语料中较少，且二元模型只能观察前一个字，无法利用更长的固定搭配。

## 5 改进方法：句首统计

普通二元模型使用全局一元概率选择首字，但高频字不一定适合作为首字。改进方法在预处理时额外统计每个文本片段的首字次数  $N_s(c)$ ，解码第一层时改用

$$P_s(c) = \frac{N_s(c) + 1}{N_s + V}. \quad (4)$$

其余位置仍使用完全相同的二元转移。该方法只增加一个计数表，不改变 Viterbi 主体，也几乎不增加训练和预测开销。

实验中句准确率从 39.52% 提升到 40.12%，说明首字先验确实修正了一些整句；字准确率从 84.05% 略降到 83.90%，说明句首分布也会在少数句子中把原本正确的高频字替换掉。该结果表明，针对句子位置建模有价值，但仅依赖句首统计仍不够稳定。若继续改进，可考虑三元模型或基于词的模型。

## 6 思考题

### 6.1 GBK、UTF-8 与其他编码

GBK 是面向简体中文的编码，兼容 GB2312，常用汉字通常占两个字节；它不覆盖全部 Unicode 字符。UTF-8 是 Unicode 的可变长编码，ASCII 字符占一个字节，中文通常占三个字节，跨平台和互联网交换时更通用。用错误编码解释同一组字节就会出现乱码，本实验因此必须在读取语料时明确指定 GBK 或兼容的 GB18030，再以 UTF-8 输出。

其他编码包括 UTF-16，常用于部分操作系统接口和需要直接处理 Unicode 码元的场景；ASCII 适合只含英文、数字和控制符的简单协议；Big5 曾广泛用于繁体中文环境。

### 6.2 Viterbi 复杂度

设输入长度为  $n$ ，字库大小为  $V$ ，读音数量为常数  $C$ ，且汉字在读音上均匀分布，则每个拼音平均有  $V/C$  个候选字。每一层需要枚举前后两层的候选字组合，因此时间复杂度为

$$O\left(n \left(\frac{V}{C}\right)^2\right). \quad (5)$$

因为  $C$  是常数，也可写为  $O(nV^2)$ 。滚动保存当前层分数只需  $O(V/C)$  空间；为了反向恢复完整路径，需要保存每层每个候选字的前驱，因此总体空间复杂度为

$$O\left(n \frac{V}{C}\right) = O(nV). \quad (6)$$

### 6.3 两种输入输出代码

代码 A 每读入一个值就立即输出，代码 B 先读到 EOF，再统一输出。对于本题这种非交互式批处理 OJ，只要输入最终会结束，并且输出顺序和内容不变，两种代码得到的标准输出都是“1、2”，因此都正确。区别只在输出发生的时间和代码 B 需要保存全部输入。若题目是交互式程序，代码 A 更合适，而且通常还需要主动刷新输出缓冲区。

## 7 总结与感受

本实验完成了从 GBK 新闻语料预处理、词频统计、概率平滑到 Viterbi 解码的完整流程。最容易出错的部分不是公式，而是编码、标点断句、标准输入输出以及未知二元组的回退。保持训练和解码代码简单，使这些问题更容易定位。

二元模型已经达到作业指标，但古诗和低频短语的错误说明局部统计存在明显上限。句首统计以很小的实现代价提高了句准确率，同时也展示了评价指标之间并非总是同步变化。完成本实验约投入数小时，主要时间用于完整语料训练、准确率核对和错误案例分析。